

## COE-835 Controle adaptativo

## Trabalho 12

**Grupo:** Guilherme Pires Sales de Carvalho  
 Matheus Ferreira dos Reis  
 Renan Salles de Freitas

**Algoritmo:** MIMO MRAC Direto ( $n^* = 2$ )

**Caso:**  $n = 2$  (ordem da planta)  
 $n^* = 2$  (grau relativo)  
 $n_p = 5, 17$  (# de parâmetros)

## Conteúdo

<b>1</b>	<b>MIMO MRAC direto (<math>n^* = 2</math>)</b>	<b>2</b>
<b>2</b>	<b>Implementação</b>	<b>4</b>
2.1	Caso em que apenas $K_p$ é desconhecido . . . . .	5
2.2	Caso onde todos os parâmetros são desconhecidos . . . . .	8
<b>3</b>	<b>Resultados das simulações</b>	<b>9</b>
3.1	Caso em que apenas $K_p$ é desconhecido . . . . .	9
3.1.1	Simulação #1 . . . . .	9
3.1.2	Simulação #2 . . . . .	10
3.1.3	Simulação #3 . . . . .	11
3.1.4	Simulação #4 . . . . .	12
3.2	Caso em que todos os parâmetros são desconhecidos . . . . .	12
3.2.1	Simulação #1 . . . . .	13
3.2.2	Simulação #2 . . . . .	13
3.2.3	Simulação #3 . . . . .	14
3.2.4	Simulação #4 . . . . .	15

## 1 MIMO MRAC direto ( $n^* = 2$ )

O controle adaptativo de modelo de referência (MRAC) é um método de controle adaptativo com uma fundação teórica rigorosa e sistemática, possui promissora e atraente perspectiva de aplicação, e seu projeto é simples e conciso. O objetivo do MRAC é garantir que a resposta de saída de um sistema controlado (planta) convirja para a resposta de um modelo de referência, dado que a planta possui parâmetros desconhecidos. Isto é feito através de uma lei de adaptação dos parâmetros do controlador que garante a estabilidade do sistema em malha fechada e a *limitação* dos parâmetros estimados.

Assim como no caso SISO, considere um sistema linear invariante no tempo descrito pela equação diferencial:

$$y(t) = P(s) [u(t)], \quad (1)$$

No caso MIMO,  $y(t) \in \mathbb{R}^n$  e  $u(t) \in \mathbb{R}^n$  são os sinais medidos de saída e entrada do sistema, sendo  $P(s) \in \mathbb{R}^{n \times n}$  a matriz função de transferência. Neste trabalho, vamos considerar o problema em que a planta possui grau relativo  $n^* = 2$ , para o caso MIMO de duas entradas e duas saídas:

$$P(s) = \begin{bmatrix} \frac{1}{s^2} & 0 \\ 0 & \frac{1}{s^2} \end{bmatrix} K_p \quad (2)$$

$$K_p = \begin{bmatrix} \cos(\phi) & \sin(\phi) \\ -h\sin(\phi) & h\cos(\phi) \end{bmatrix}$$

Como no caso de grau relativo  $n^* = 1$ , a matriz *interactor* de  $P(s)$  é tal que:

$$\lim_{s \rightarrow \infty} \xi(s) P(s) = K_p \quad (3)$$

é não singular. No caso de grau relativo 2 ( $n^* = 2$ ), a matriz *interactor* é  $\xi(s) = s^2 I$ .

Define-se índice de observabilidade  $\nu$  como os graus dos polinômios da matriz  $P(s)$ . E *observability index* como o maior grau.

Dado um modelo de referência descrito como:

$$y_M(t) = M(s)r(t), \quad (4)$$

onde  $M(s) = \text{diag} \left\{ \frac{1}{(s+a_i)(s+\lambda)} \right\}$  é uma matriz diagonal com polinômios estáveis e mônicos, e  $r(t) \in \mathbb{R}^n$  é a entrada do sistema MIMO, sinal limitado. O objetivo é encontrar uma lei de controle  $u(t)$  tal que todo o sistema de malha fechada produza sinais limitados e a saída da planta  $y(t)$  rastree assintoticamente o modelo de referência  $y_M(t)$ . A estrutura exige algumas premissas:

1. Os zeros de  $P(s)$  tem parte real negativa;
2.  $P(s)$  tem posto completo e grau relativo 2;
3. O *Observability index* de  $P(s)$  é conhecido;
4. Os sinais dos menores principais líderes da matriz  $K_p$  são conhecidos.
5. O modelo de referencia é dado por uma função de transferência  $P_M(s)$ . E  $M(s)L(s)$  é SPR, onde  $L(s) = (s + \lambda)I$ .

É possível provar que existe uma fatoração SDU não única de  $K_p$  (notas de aula). Assim como caso SISO, a estrutura do controlador é 2DOF. Escolhe-se então um polinômio estável  $\Lambda(s) = \text{diag} \{(s + a_i)^{\nu-1}\}$  para filtrar a entrada e a saída da planta com o filtro  $\frac{1}{\Lambda(s)}$ . O filtro é descrito pela realização de estados:

$$\dot{\omega}_1(t) = A_\lambda \omega_1(t) + B_\lambda u(t), \quad (5)$$

$$\dot{\omega}_2(t) = A_\lambda \omega_2(t) + B_\lambda y(t), \quad (6)$$

Observe que agora  $B_\lambda$  é matriz para o caso MIMO. Podemos, então, formular a equação do erro:

$$\begin{aligned}
 e &= M(s)K_p [u - \theta^{*\top} \omega] \\
 &= M(s)SD [Uu - U\theta_1^{*\top} \omega_1 - U\theta_2^{*\top} \omega_2 - U\theta_3^{*\top} y - U\theta_4^{*\top} r] \\
 &= M(s)SD [u - K_1 \omega_1 - K_2 \omega_2 - K_3 y - K_4 r - K_5 u] \\
 &= M(s)SD [u - u^*]
 \end{aligned} \tag{7}$$

Notar que  $K_5$  é matriz estritamente superior. E  $u^*$  pode ser descrito como:

$$u^* = \begin{bmatrix} \Theta_1^{*\top} \Omega_1 \\ \Theta_2^{*\top} \Omega_2 \\ \vdots \\ \Theta_m^{*\top} \Omega_m \end{bmatrix} \tag{8}$$

onde  $\Omega_i$  são os novos regressores para o caso MIMO:

$$\begin{aligned}
 \Omega_1^\top &= [\omega^\top \quad u_2 \quad u_3 \quad \dots \quad u_m] \\
 \Omega_2^\top &= [\omega^\top \quad u_3 \quad \dots \quad u_m] \\
 &\vdots \\
 \Omega_m^\top &= [\omega^\top] \\
 \Omega^\top &= \begin{bmatrix} \Omega_1^\top & 0 & \dots & 0 \\ 0 & \Omega_2^\top & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \Omega_m^\top \end{bmatrix}
 \end{aligned} \tag{9}$$

e  $\Theta$  é o vetor de parâmetros:

$$\Theta^\top = \begin{bmatrix} \Theta_1^* \\ \Theta_2^* \\ \vdots \\ \Theta_m^* \end{bmatrix} \tag{10}$$

A nova estrutura MIMO MRAC pode ser vista na figura 1.

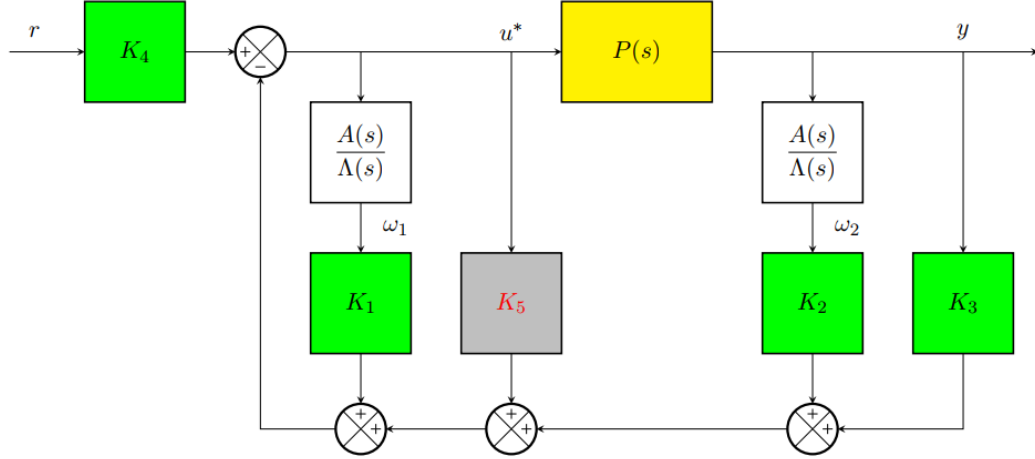


Figura 1: Estrutura MIMO MRAC.

Utilizando o algoritmo de Monopoli, temos:

$$e = [M(s)S] DL(s)L^{-1}(s) [u - \Omega^T \Theta^*] \quad (11)$$

$$= [M(s)L(s)S] D [L^{-1}(s)u - L^{-1}(s)\Omega^T \Theta^*] \quad (12)$$

$$u = L(s)\chi \quad (13)$$

Escolhmos:

$$\chi = \zeta^T \Omega \quad (14)$$

$$u = \Omega^T \Omega + \zeta^T \dot{\Omega} \quad (15)$$

Como no caso  $n^* = 1$ , é possível provar que para todo modelo de referência  $M(s)$  existe  $D_+$  tal que  $M(s)L(s)S = M(s)L(s)L_1 D_+ L_1^T$  é SPR. Escolhendo a função de Lyapunov:

$$2V = z^T P_M z + \tilde{\Theta}^T |D| \Gamma^{-1} \tilde{\Theta} \quad (16)$$

podemos chegar na lei de adaptação:

$$\dot{\Theta}(t) = -\text{sign}[D] \Gamma \zeta e(t), \quad (17)$$

onde  $D = \text{diag} \{d_1 I_1, d) 2I_2, \dots, d_m I_m\}$

o erro converge assintoticamente para zero, em que  $\Gamma = \Gamma^T > 0$  é uma matriz de ganhos positiva definida.

Observe que ainda falta analisar a estabilidade de  $L(s)$ . Nas notas de aula, pode-se verificar a prova completa com a segunda lei de Lyapunov:

$$V_L(z, \epsilon, \tilde{\Theta}) = V + \alpha \epsilon^T P_1 \epsilon \quad (18)$$

Neste trabalho, serão consideradas plantas de primeira e segunda ordens com grau relativo 2 ( $n^* = 2$ ). Iremos simular e discutir o comportamento do erro e das saídas para variações das condições iniciais dos parâmetros estimados ( $\theta(0)$ ) e da planta ( $y(0)$ ), do ganho de adaptação  $\Gamma$  e para diferentes parâmetros da planta e modelo.

## 2 Implementação

Foram considerados dois casos: caso em que  $K_p$  é desconhecido; e caso em que todos os parâmetros da planta são desconhecidos.

## 2.1 Caso em que apenas $K_p$ é desconhecido

Consideremos a planta descrita pela eq. 2. A equação ideal para o controlador 2DOF poode ser computada pela equação do erro eq. 7:

$$\begin{aligned} u^* &= \theta_1^{*\top} \omega_1 + \theta_2^{*\top} \omega_2 + \theta_3 y + \theta_4 r \\ \omega_1 &= \frac{u^*}{\Lambda} \\ \omega_2 &= \frac{y}{\Lambda} \\ (I - \theta_1^{*\top} \Lambda^{-1}) u^* &= \theta_2^{*\top} \Lambda^{-1} y + \theta_3 y + \theta_4 r \end{aligned}$$

Temos que:

$$\frac{1}{\Lambda(s)} = \begin{bmatrix} \frac{1}{(s+\lambda_f)} & 0 \\ 0 & \frac{1}{(s+\lambda_f)} \end{bmatrix}$$

e

$$M(s) = \begin{bmatrix} \frac{\lambda^2}{(s+\lambda)^2} & 0 \\ 0 & \frac{\lambda^2}{(s+\lambda)^2} \end{bmatrix}$$

Voltando à equação da planta:

$$\begin{aligned} y &= PK_p u \\ (I - \theta_1^{*\top} \Lambda^{-1}) y &= (I - \theta_1^{*\top} \Lambda^{-1}) P \bar{u} \end{aligned}$$

Como  $P(s)$  é diagonal, temos  $AP = PA$  (comuta). E  $y = y_m$ , logo:

$$\begin{aligned} (I - \theta_1^{*\top} \Lambda^{-1}) y_m &= P (I - \theta_1^{*\top} \Lambda^{-1}) \bar{u} \\ (I - \theta_1^{*\top} \Lambda^{-1}) M(s) r &= P(\theta_2^{*\top} \Lambda^{-1} y_m + \theta_3 y_m + \theta_4 r) \\ (I - \theta_1^{*\top} \Lambda^{-1}) M(s) r &= P(\theta_2^{*\top} \Lambda^{-1} M(s) r + \theta_3 M(s) r + \theta_4 r) \\ (I - \theta_1^{*\top} \Lambda^{-1}) M(s) r &= P(\theta_2^{*\top} \Lambda^{-1} M(s) + \theta_3 M(s) + \theta_4) r \\ (I - \theta_1^{*\top} \Lambda^{-1}) M(s) &= P(\theta_2^{*\top} \Lambda^{-1} M(s) + \theta_3 M(s) + \theta_4) \end{aligned}$$

$$\begin{aligned} & \left( \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} - \theta_1^{*\top} \begin{bmatrix} \frac{1}{(s+\lambda_f)} & 0 \\ 0 & \frac{1}{(s+\lambda_f)} \end{bmatrix} \right) \begin{bmatrix} \frac{\lambda^2}{(s+\lambda)^2} & 0 \\ 0 & \frac{\lambda^2}{(s+\lambda)^2} \end{bmatrix} = \\ & \begin{bmatrix} \frac{1}{s^2} & 0 \\ 0 & \frac{1}{s^2} \end{bmatrix} \left( \theta_2^{*\top} \begin{bmatrix} \frac{1}{(s+\lambda_f)} & 0 \\ 0 & \frac{1}{(s+\lambda_f)} \end{bmatrix} \begin{bmatrix} \frac{\lambda^2}{(s+\lambda)^2} & 0 \\ 0 & \frac{\lambda^2}{(s+\lambda)^2} \end{bmatrix} + \theta_3 \begin{bmatrix} \frac{\lambda^2}{(s+\lambda)^2} & 0 \\ 0 & \frac{\lambda^2}{(s+\lambda)^2} \end{bmatrix} + \theta_4 \right) \end{aligned}$$

Como todas as matrizes são diagonais, vamos resolver para o primeiro termo:

$$\left(1 - \frac{\theta_1}{(s + \lambda_f)}\right) \frac{\lambda^2}{(s + \lambda)^2} = \frac{1}{s^2} \left( \frac{\theta_2}{(s + \lambda_f)} \frac{\lambda^2}{(s + \lambda)^2} + \theta_3 \frac{\lambda^2}{(s + \lambda)^2} + \theta_4 \right)$$

$$(\lambda^2 - \theta_4)s^3 + (\lambda^2\lambda_f - \theta_1\lambda^2 - \theta_4(\lambda_f + 2\lambda))s^2 + (-\theta_3\lambda^2 - \theta_4(2\lambda\lambda_f + \lambda^2))s + (-\theta_2\lambda^2 - \theta_3\lambda^2\lambda_f - \theta_4\lambda^2\lambda_f) = 0$$

Resolvendo para  $\theta$ , temos:

$$\begin{aligned}\theta_4 &= \lambda^2 \\ \theta_1 &= -2\lambda \\ \theta_3 &= -(2\lambda\lambda_f + \lambda^2) \\ \theta_2 &= 2\lambda\lambda_f^2\end{aligned}$$

Dessa forma, a lei de controle é descrita como:

$$u^* = K_p^{-1} [2\lambda\lambda_f^2\Lambda^{-1}y - (\lambda^2 + 2\lambda\lambda_f)y + \lambda^2r] - 2\lambda\Lambda^{-1}u \quad (19)$$

Utilizando o algoritmo de Monopoli [11](#), temos:

$$u = \Omega^T\Theta + \zeta^T\dot{\Theta} - 2\lambda\omega_1 \quad (20)$$

$$\Omega_1^T = [\omega^T \quad u_2 + 2\lambda\omega_{12}]$$

$$\Omega_2^T = [\omega^T] \quad (21)$$

$$\omega = 2\lambda\lambda_f^2\omega_2 - (\lambda^2 + 2\lambda\lambda_f)y + \lambda^2r \quad (22)$$

$$\omega_f = L^{-1}(s)\omega \quad (23)$$

$$\zeta_1^T = \omega_f^T [I \quad \Theta_2]$$

$$\zeta_2^T = \omega_f^T \quad (24)$$

$$\dot{\Theta} = -\text{sign}(D)\Gamma\zeta e \quad (25)$$

A implementação segue abaixo:

```

1 %=====
2 %
3 % COE-835 Controle adaptativo
4 %
5 % Script para simular o exemplo
6 %
7 % MRAC : n = 2 First order plant
8 %        n* = 2 Relative degree
9 %        np = 5 Adaptive parameters
10 %
11 %=====
12 function dx=mrac(t,x)
13
14 global sysP sysM sysL gamma a1 a2 w1 w2 lambda lambda_f;
15
16 xp = x(1:4);

```

```

17 xm      = x(5:8);
18 uf      = x(9:10);
19 yf      = x(11:12);
20 omega_f  = x(13:14);
21 theta   = x(15:end);
22
23 y = sysP.C*xp;
24 ym = sysM.C*xm;
25 %-----
26 r1 = 0;
27 r2 = 0;
28 for i=1:length(w1)
29     r1 = r1 + a1(i)*sin(w1(i)*t);
30     r2 = r2 + a2(i)*sin(w2(i)*t);
31 end
32
33 r = [r1 r2]';
34
35 theta_2_omega_2 = 2*lambda*lambda_f^2*yf;
36 theta_3_y = - (lambda^2 + 2*lambda*lambda_f)*y;
37 theta_4_r = lambda^2*r;
38
39 omega = theta_2_omega_2 + theta_3_y + theta_4_r;
40 zeta1 = (omega_f'*[eye(2) theta(4:5)])';
41 zeta2 = omega_f;
42
43 e = y - ym;
44
45 %% ----- Adaptacao -----
46 dtheta = -gamma*[zeta1'*e(1), zeta2'*e(2)]';
47
48 %% ----- u -----
49 Omega2 = omega;
50 u2 = Omega2'*theta(4:5) + zeta2'*dtheta(4:5) - 2*lambda*uf(2);
51
52 Omega1 = [omega' u2+2*lambda*uf(2)]';
53 u1 = Omega1'*theta(1:3) + zeta1'*dtheta(1:3) - 2*lambda*uf(1);
54
55 u = [u1 u2]';
56
57 %% ----- Planta -----
58 dxp = sysP.A*xp + sysP.B*u;
59
60 %% ----- Modelo -----
61 dxm = sysM.A*xm + sysM.B*r;
62
63 %% ----- omega_1 -----
64 duf = sysL.A*uf + sysL.B*u;
65
66 %% ----- omega_2 -----
67 dyf = sysL.A*yf + sysL.B*y;
68
69 %% ----- omega_f -----
70 domega_f = sysL.A*omega_f + sysL.B*omega;
71
72 %-----
73 dx = [dxp' dxm' duf' dyf' domega_f' dtheta']'; %Translation
74
75 %-----

```

## 2.2 Caso onde todos os parâmetros são desconhecidos

```

1 %=====
2 %
3 % COE-835 Controle adaptativo
4 %
5 % Script para simular o exemplo
6 %
7 % MRAC : n = 2      First order plant
8 %       n* = 2      Relative degree
9 %       np = 17     Adaptive parameters
10 %
11 %=====
12 function dx=mrac(t,x)
13
14 global sysP sysM sysL gamma w1 w2 a1 a2;
15
16 xp      = x(1:4);
17 xm      = x(5:8);
18 uf      = x(9:10);
19 yf      = x(11:12);
20 omega_f = x(13:20);
21 theta   = x(21:end);
22
23 y = sysP.C*xp;
24 ym = sysM.C*xm;
25 %-----
26 r1 = 0;
27 r2 = 0;
28 for i=1:length(w1)
29     r1 = r1 + a1(i)*sin(w1(i)*t);
30     r2 = r2 + a2(i)*sin(w2(i)*t);
31 end
32
33 r = [r1 r2]';
34
35 omega = [uf' yf' y' r']';
36 zeta1 = (omega_f'*[eye(8) theta(10:end)])';
37 zeta2 = omega_f;
38
39 e = y - ym;
40
41 %% ----- Adaptacao -----
42 dtheta = -gamma*[zeta1'*e(1), zeta2'*e(2)]';
43
44 %% ----- u -----
45 Omega2 = omega;
46 u2 = Omega2'*theta(10:end) + zeta2'*dtheta(10:end);
47
48 Omega1 = [omega' u2]';
49 u1 = Omega1'*theta(1:9) + zeta1'*dtheta(1:9);
50
51 u = [u1 u2]';
52
53 %% ----- Planta -----
54 dxp = sysP.A*xp + sysP.B*u;
55
56 %% ----- Modelo -----
57 dxm = sysM.A*xm + sysM.B*r;

```



```

58
59 %% ----- omega_1 -----
60 duf = sysL.A*uf + sysL.B*u;
61
62 %% ----- omega_2 -----
63 dyf = sysL.A*yf + sysL.B*y;
64
65 %% ----- omega_f -----
66 domega_f = sysL.A*omega_f + sysL.B*omega;
67
68 %-----
69 dx = [dxp' dxm' duf' dyf' domega_f' dtheta']'; %Translation

```

### 3 Resultados das simulações

Nas simulações, procuramos avaliar o comportamento do sistema para as seguintes condições: (i) Condições iniciais  $y(0)$ ; (ii) Parâmetros da planta e do modelo; (iii) ganho de adaptação  $\Gamma$ .

Apresentaremos os resultados obtidos através de simulações no ambiente **Matlab/Simulink** e os discutiremos na próxima seção.



#### 3.1 Caso em que apenas $K_p$ é desconhecido

$$\begin{aligned}
 P(s) &= \begin{bmatrix} \frac{1}{s^2} & 0 \\ 0 & \frac{1}{s^2} \end{bmatrix} K_p, \\
 K_p &= \begin{bmatrix} \cos(\phi) & \sin(\phi) \\ -h\sin(\phi) & h\cos(\phi) \end{bmatrix} \\
 M(s) &= \begin{bmatrix} \frac{\lambda^2}{s+\lambda^2} & 0 \\ 0 & \frac{\lambda^2}{s+\lambda^2} \end{bmatrix} \\
 r_1 &= \sin(0.635t) + \sin(4.567t) \\
 r_2 &= \sin(0.1t) + \sin(1.1t)
 \end{aligned}$$

##### 3.1.1 Simulação #1

Inicialmente, verificamos o comportamento do sistema para variações no **parâmetro de adaptação**  $\Gamma$ .

$$\begin{aligned}
 \phi &= \frac{\pi}{4}, & h &= 1, \\
 y(0) &= \mathbf{0}, & \gamma &= 10, \text{ e } 50
 \end{aligned}$$





### 3.1.2 Simulação #2

Verificamos agora o comportamento do sistema para variações na **condição inicial**  $y(0)$ .

$$\phi = \frac{\pi}{4}, \quad h = 1,$$

$$y(0) = \begin{bmatrix} 0 \\ 0 \\ 0 \\ 0 \end{bmatrix} \text{ e } \begin{bmatrix} 10 \\ 10 \\ 0 \\ 0 \end{bmatrix}, \quad \gamma = 10$$



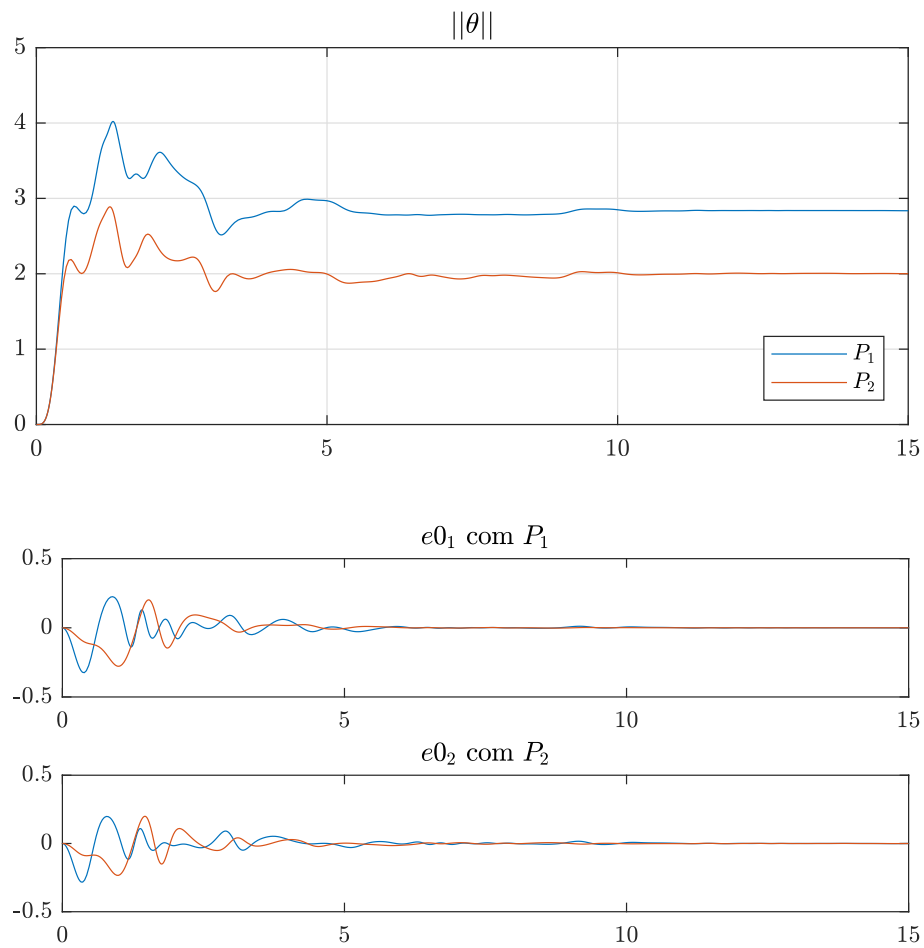


### 3.1.3 Simulação #3

Verificamos o comportamento do sistema para variações na **função de transferência da planta**  $P(s)$ .

$$\phi = \begin{bmatrix} \frac{\pi}{4} \\ \frac{\pi}{3} \end{bmatrix}, \quad h = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

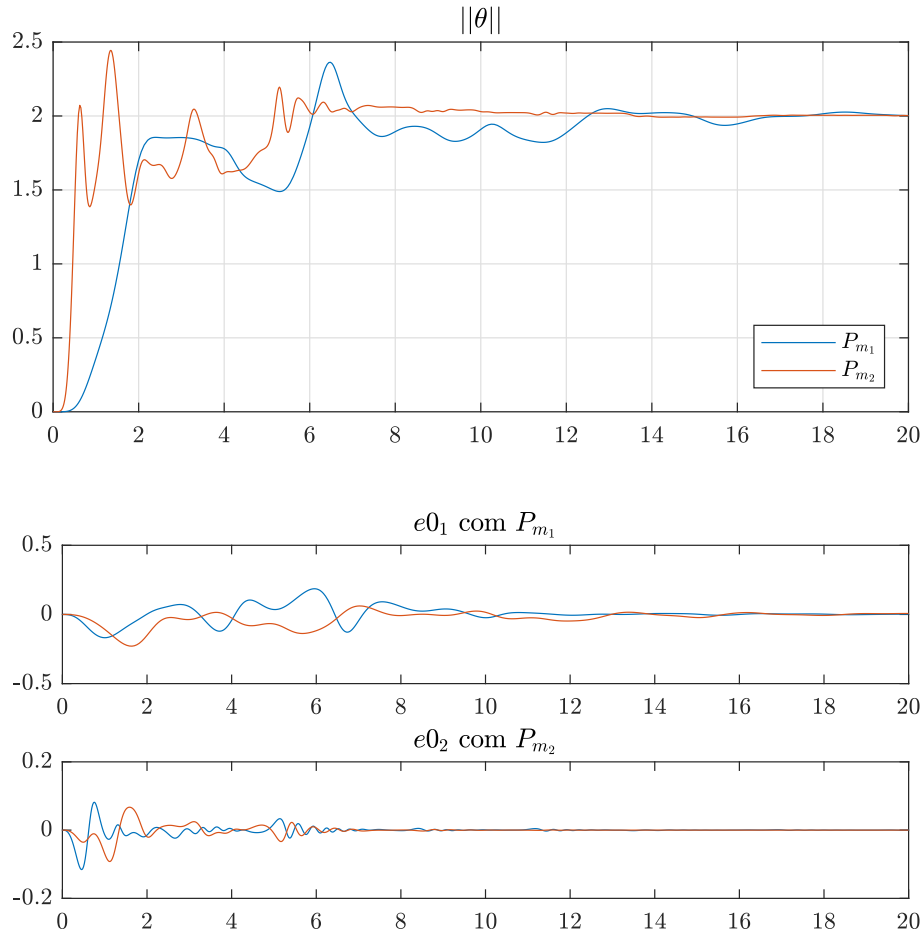
$$y(0) = \mathbf{0}, \quad \gamma = 10$$



### 3.1.4 Simulação #4

Verificamos o comportamento do sistema para variações na **função de transferência do modelo de referência**  $P_m(s)$ .

$$\begin{aligned} \phi &= \frac{\pi}{4}, & h &= 1 \\ y(0) &= \mathbf{0}, & \gamma &= 10, & \lambda &= 1 \text{ e } 2 \end{aligned}$$



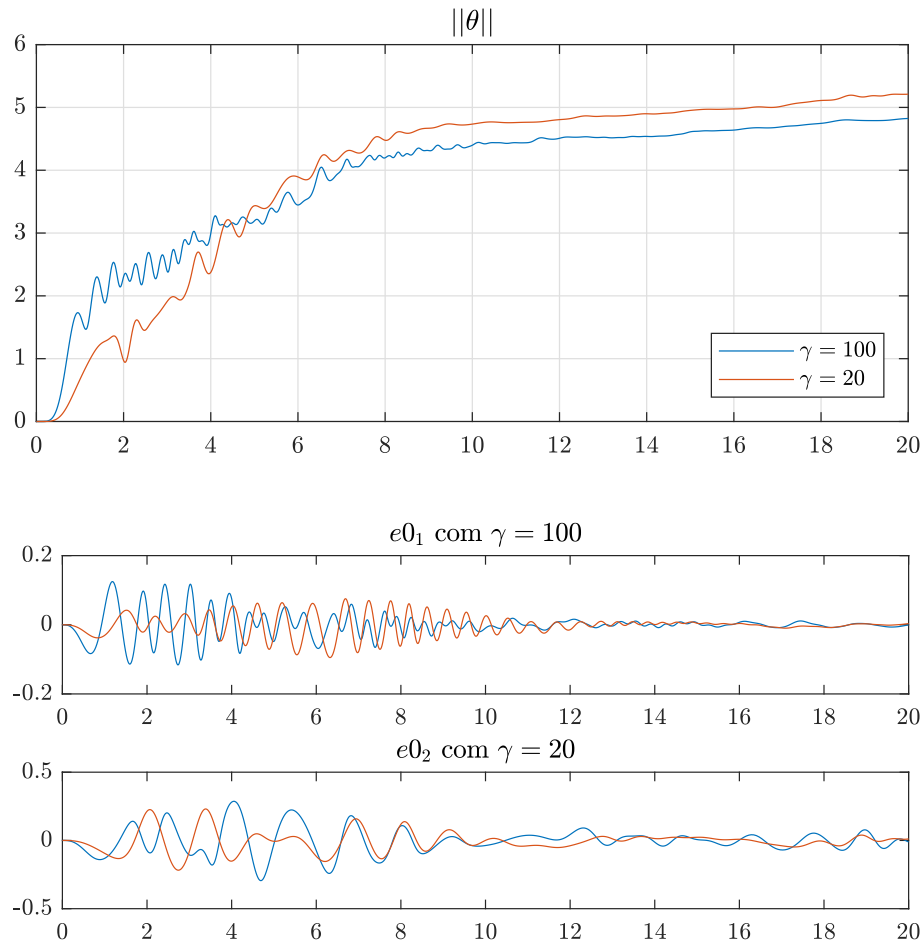
### 3.2 Caso em que todos os parâmetros são desconhecidos

$$\begin{aligned} P(s) &= \begin{bmatrix} \frac{1}{s^2} & 0 \\ 0 & \frac{1}{s^2} \end{bmatrix} K_p, \\ K_p &= \begin{bmatrix} \cos(\phi) & \sin(\phi) \\ -h\sin(\phi) & h\cos(\phi) \end{bmatrix} \\ M(s) &= \begin{bmatrix} \frac{\lambda^2}{s+\lambda^2} & 0 \\ 0 & \frac{\lambda^2}{s+\lambda^2} \end{bmatrix} \\ r_1 &= \sin(0.635t) + \sin(4.567t) \\ r_2 &= \sin(0.1t) + \sin(1.1t) \end{aligned}$$

### 3.2.1 Simulação #1

Inicialmente, verificamos o comportamento do sistema para variações no **parâmetro de adaptação**  $\Gamma$ .

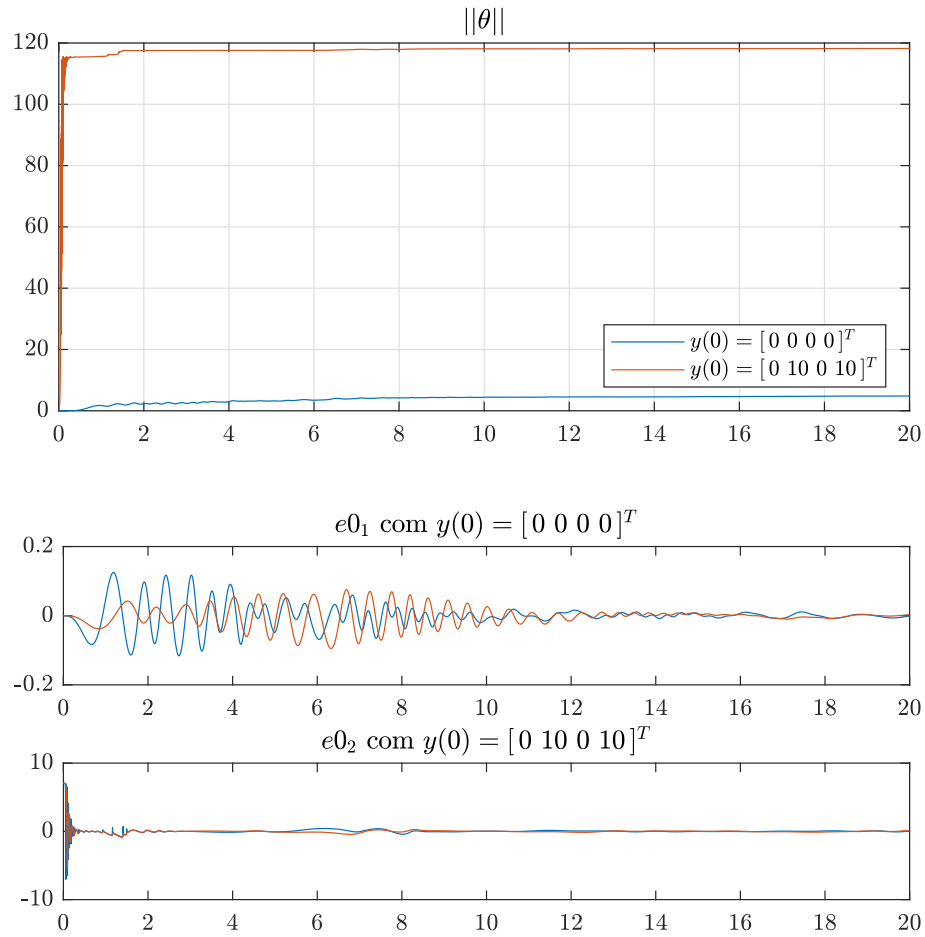
$$\begin{aligned} \phi &= \frac{\pi}{4}, & h &= 1, \\ y(0) &= \mathbf{0}, & \gamma &= \mathbf{100}, \text{ e } \mathbf{20} \end{aligned}$$



### 3.2.2 Simulação #2

Verificamos agora o comportamento do sistema para variações na **condição inicial**  $y(0)$ .

$$\begin{aligned} \phi &= \frac{\pi}{4}, & h &= 1, \\ y(0) &= \mathbf{0} \text{ e } \mathbf{10}, & \gamma &= 100 \end{aligned}$$



### 3.2.3 Simulação #3

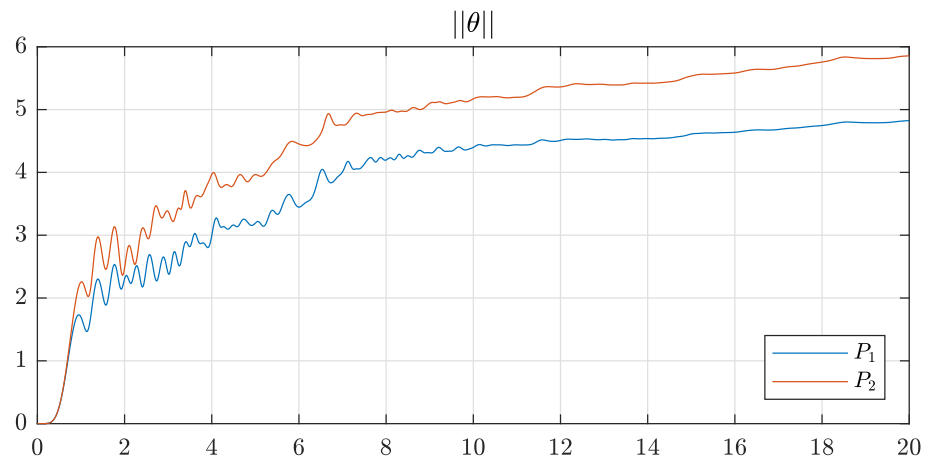
Verificamos o comportamento do sistema para variações na **função de transferência da planta**  $P(s)$ .


$$\phi = \frac{\pi}{4} e \frac{\pi}{3},$$

$$y(0) = \mathbf{0},$$

$$h = 1 e 2,$$

$$\gamma = 100$$

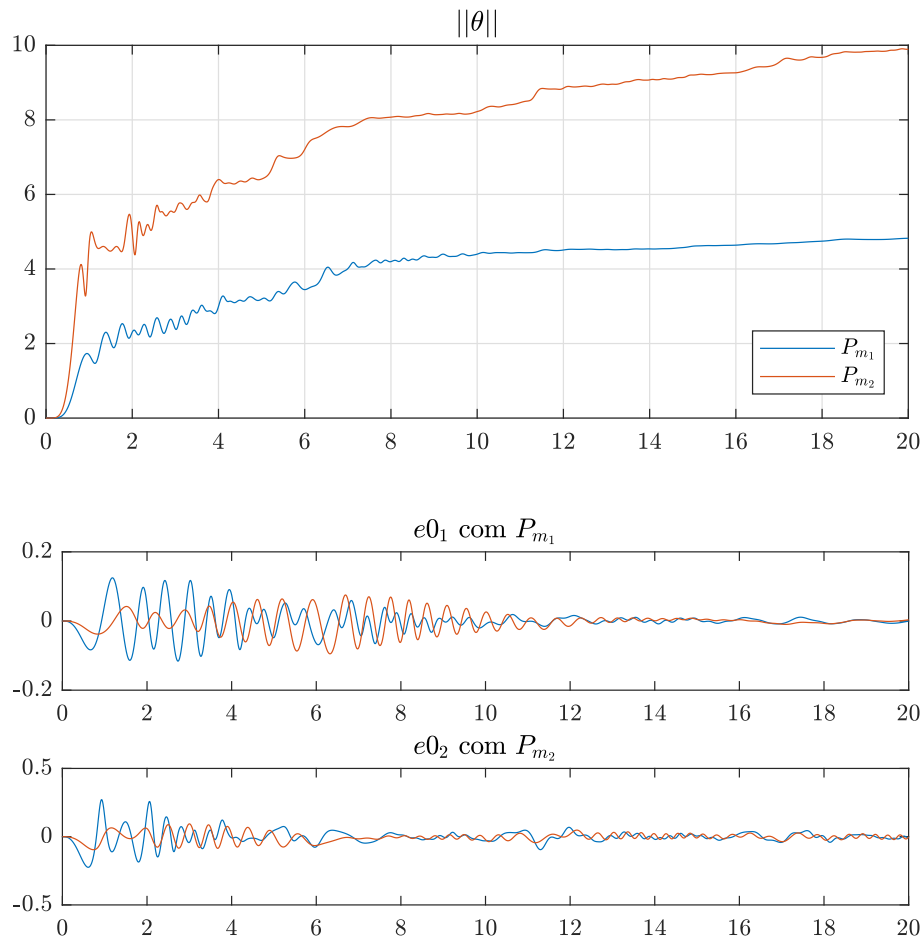




### 3.2.4 Simulação #4

Verificamos o comportamento do sistema para variações na **função de transferência do modelo de referência**  $P_m(s)$ .

$$\begin{aligned} \phi &= \frac{\pi}{4}, & h &= 1 \\ y(0) &= \mathbf{0}, & \gamma &= 100, & \lambda &= 1 \text{ e } 2 \end{aligned}$$



## 4 Discussão

Os resultados apresentados neste trabalho são semelhantes aos apresentados nos trabalhos anteriores sobre MRAC, só que aplicado a sistemas MIMO. Neste trabalho, são abordados sistemas com duas entradas e duas saídas e plantas de segunda ordem com grau relativo 2. O filtro foi definido como mais simples possível.

Comparativamente, quando apenas  $K_p$  é desconhecido (5 parâmetros), o erro converge rapidamente para zero, aproximadamente 15 segundos, usando ganhos de adaptação  $\Gamma$  entre 10 e 50. O erro leva mais tempo para convergir para zero quando todos os parâmetros são desconhecidos (17 parâmetros), aproximadamente 30 segundos, o ganho de adaptação deve ser bem maior (100), e o tempo de simulação é, também, bem mais elevado, pois a *ode* calcula a derivada de 17 parâmetros.

A **simulação #1** mostra o comportamento do sistema para variações no ganho de adaptação  $\Gamma$ . Como nos trabalhos anteriores, aumentar o ganho de adaptação garante convergência mais rápida, porém mais oscilações.

A **simulação #2** mostra o comportamento do sistema para variações nas condições iniciais da planta  $y(0)$ . O sistema oscila mais para condições iniciais da planta longe de zero. O transitório, porém, foi menor para os sistemas com condição inicial diferente de zero. Isso ocorre, pois os parâmetros entraram rapidamente em quadratura com o vetor de regressor.

A **simulação #3** mostra o comportamento do sistema para variações no ganho de adaptação na planta. A planta com maior deslocamento,  $\phi = \frac{\pi}{3}$ , teve melhor transitório e convergiu mais rápido, mostrando que é difícil prever o comportamento comparativo quando alteramos a planta.

A **simulação #4** mostra o comportamento do sistema para variações no modelo. Modelos mais rápidos apresentaram maiores oscilações.